AutoTutor-CP

IA na aprendizagem de programação competitiva

Fundamentos, implementação e auditoria científica

Como combinar geração, recuperação e verificação em um tutor confiável?

Brenno Phelipe Silva dos Santos

Fundamentos da Inteligência Artificial / 05 de novembro de 2026

Motivação e hipótese de trabalho

Problema documentado

Criar problemas e testes exige precisão
Erros do aluno precisam orientar a tutoria
Uma resposta plausível pode conter falhas

Hipótese reconstruída

Vereditos e contraexemplos podem fundamentar feedback mais específico
Recuperação pode apoiar explicações e prática relacionada

A hipótese pedagógica ainda requer avaliação com estudantes

Referências R1, R2, R3. Fontes e evidências detalhadas nas notas.

Proposta e estado verificado

Objetivo	Evidência atual	Estado
Juiz local e vereditos	C++17, limites e testes	Funcional
Tutoria por dificuldades	Prompts com caso e histórico	Parcial
Problemas inéditos	Adaptação de 39 contratos	Parcial
Recuperação multivetor	Três espaços TF-IDF e reranker	Adaptado
Busca semântica do acervo	Experimento separado com embeddings	Experimental
Eficácia pedagógica	Sem estudo local com participantes	Não demonstrada

Funcionalidade executável e validade científica exigem evidências distintas

Referências R1, R2, R3. Fontes e evidências detalhadas nas notas.

Artigos que fundamentaram a proposta

Trabalho	Método e avaliação reportada	Limite da interpretação
AutoCode **Zhou et al., ICLR 2026**	Validação multirrodadas 91,1% em 7.538 problemas 98,7% em outro conjunto de 720	Concordância de vereditos Conjuntos e modelos distintos
OI-Assistant **Su, Nie e Meng, 2025**	11.000 problemas Luogu 900 consultas de recuperação 36 estudantes na avaliação de uso	Recall e satisfação Não provam aprendizagem causal
Codigen **Ez-zaouia e Boumarafi, 2025**	Autoria visual e ajuda in situ 29 participantes no total Resultados distintos por experiência	Conteúdo de JavaScript Sem equivalência com nosso tutor

AutoCode, OI-Assistant e Codigen são trabalhos diferentes

Referências R1, R2, R3. Fontes e evidências detalhadas nas notas.

Adaptação dos métodos científicos

Referência	Ideia aproveitada	Diferença da implementação
AutoCode	Testes de borda e cruzamento de soluções	Contratos fixos e oráculos próprios Sem checkers ou interactors gerados
OI-Assistant	Separar narrativa, conceito e estratégia	TF-IDF com NumPy Sem FAISS na aplicação
Codigen	Prompter e ajuda no contexto do código	Streamlit e juiz C++ Sem reprodução do canvas visual
RAG de Lewis et al.	Condicionar a resposta a evidência externa	Recuperar e compor prompt Sem treinamento conjunto

A contribuição atual combina e delimita métodos existentes

Referências R1, R2, R3, R5. Fontes e evidências detalhadas nas notas.

LLMs e geração condicionada

$$p_\theta(y \mid x) = \prod_t p_\theta(y_t \mid x, y_{<t})$$

x contém o pedido e as evidências
y_t é o próximo token gerado

$$\text{Attention}(Q,K,V) = \text{softmax}(QK^T / \sqrt{d_k})V$$

Representação

Tokens formam a sequência
Atenção relaciona posições do contexto

Condicionamento

Instruções definem o papel do tutor
Few-shot mostra exemplos de feedback

Probabilidade de texto e correção algorítmica são propriedades diferentes

Referências R4. Fontes e evidências detalhadas nas notas.

Inferência local em uma máquina de 8 GB

Configuração implementada

Llama 3.2 1B experimental
Ollama em loopback
2 threads, contexto de 4.096 tokens
Descarregamento após cada resposta

Decisão e alternativas

Memória dos pesos ≈ P × b / 8 bytes
Contexto e ativações acrescentam custo
Qwen2.5-Coder 1.5B é candidato futuro
3B exige medir memória e latência

Menor consumo permite executar, mas não estabelece qualidade pedagógica

Referências R15, R16. Fontes e evidências detalhadas nas notas.

RAG de materiais: indexação e contexto

01

Fonte externa

Texto com URL, revisão e licença

02

Indexação

Trechos de até 1.800 caracteres

03

Recuperação

FTS5/BM25 e filtros de conteúdo

04

Inferência

Pedido, trechos e estatísticas

05

Persistência

Material e fontes recuperadas

Corpos comprimidos e índice textual no SQLite
Fontes recuperadas e links recomendados permanecem identificados

Guardar documentos atualiza a memória externa consultável

Referências R5, R14. Fontes e evidências detalhadas nas notas.

Recuperação de problemas e de materiais

$sim(a,b) = (a \cdot b) / (\|a\| \|b\|)$

Produto interno mede alinhamento
Normas removem o efeito da magnitude

score = 0,25 × questão + 0,45 × conceitos + 0,30 × estratégia

Problemas

Três espaços TF-IDF normalizados
NumPy calcula o cosseno
LLM reordena candidatos

Materiais

FTS5/BM25 sobre trechos
Aliases português e inglês
Bônus de título e base

Proximidade textual não comprova equivalência algorítmica

Referências R2, R6, R7, R8, R14. Fontes e evidências detalhadas nas notas.

Cobertura real do acervo

302
textos externos completos

5.230
referências e metadados

39
contratos corrigíveis localmente

Texto disponível

164 artigos CP-Algorithms
138 tutoriais USACO Guide
19 aulas/guias locais fora do RAG externo

Limites de cobertura

Vídeos sem transcrições
Links não equivalem a conteúdo integral
Catálogo TLE bloqueou a consulta pública

5.551 registros no banco não representam 5.551 textos externos completos

Referências R2, R5. Fontes e evidências detalhadas nas notas.

Geração e verificação de um problema

01

Pedido específico

Assunto e objetivos do aluno

02

Seleção por LLM

Escolha entre 39 contratos

03

Adaptação

Enunciado e soluções C++17

04

Verificação

Entradas válidas e oráculos

05

Publicação

Exemplos conferidos e origem salva

Testes pequenos enumerados, extremos e entradas grandes
Referência confiável e oráculos verificam as saídas

A etapa de seleção recebe o catálogo no prompt, sem busca RAG de candidatos

Referências R1. Fontes e evidências detalhadas nas notas.

Arquitetura realmente implementada



Recuperação, decisões da IA e juiz mantêm responsabilidades distintas

Referências R14, R15. Fontes e evidências detalhadas nas notas.

Fundamentos pedagógicos e evidências

Fundamento	Correspondência atual	Evolução necessária
Feedback formativo	Veredito, contraexemplo e pergunta	Medir especificidade e utilidade
Scaffolding	Dicas e lacunas sob demanda	Ajustar e retirar ajuda com evidências
Bloom e objetivos	Exemplos, explicações e exercícios	Rotular e avaliar processos cognitivos
ZDP e mastery learning	Pré-requisitos e estatísticas	Modelo de domínio e critérios validados

São relações conceituais possíveis, sem validação pedagógica local

Referências R3, R9, R10, R11, R12, R13. Fontes e evidências detalhadas nas notas.

Evolução documentada do projeto

Setembro

Proposta e apresentação inicial

AutoCode como base
Juiz local e tutoria por erros

Out. / nov.

Expansão do protótipo

APIs, biblioteca e estudos
Turmas e trilhas solicitadas

04 novembro

Registros técnicos preservados

39 contratos e atualização USACO
Comparações de modelos e busca

05 novembro

Auditoria do estado atual

Rastreabilidade e revisão científica
Novos experimentos propostos

Sem repositório Git disponível, a ordem exata das mudanças não é verificável

Evidências locais e limites detalhados nas notas.

Três níveis de avaliação

Nível	Procedimento	O que a evidência sustenta
Engenharia	Testes automatizados de contratos, privacidade, integração e interface	Comportamento nos cenários testados
Recuperação	12 consultas em português Título esperado entre top-3	Acerto tópico aproximado
Geração local	Cinco questões numéricas JSON, justificativa e rótulos	Conformidade e erros da amostra

Nenhum protocolo local mede ganho de aprendizagem ou equivalência com juiz oficial

Evidências locais e limites detalhados nas notas.

Resultados positivos verificáveis

39

contratos com referências e testes

207

testes aprovados nesta auditoria

138

tutoriais atualizados sem duplicação

Integridade do sistema

Oráculos e comparação diferencial
Persistência separada por perfil
Validação de IDs, tempo e pré-requisitos

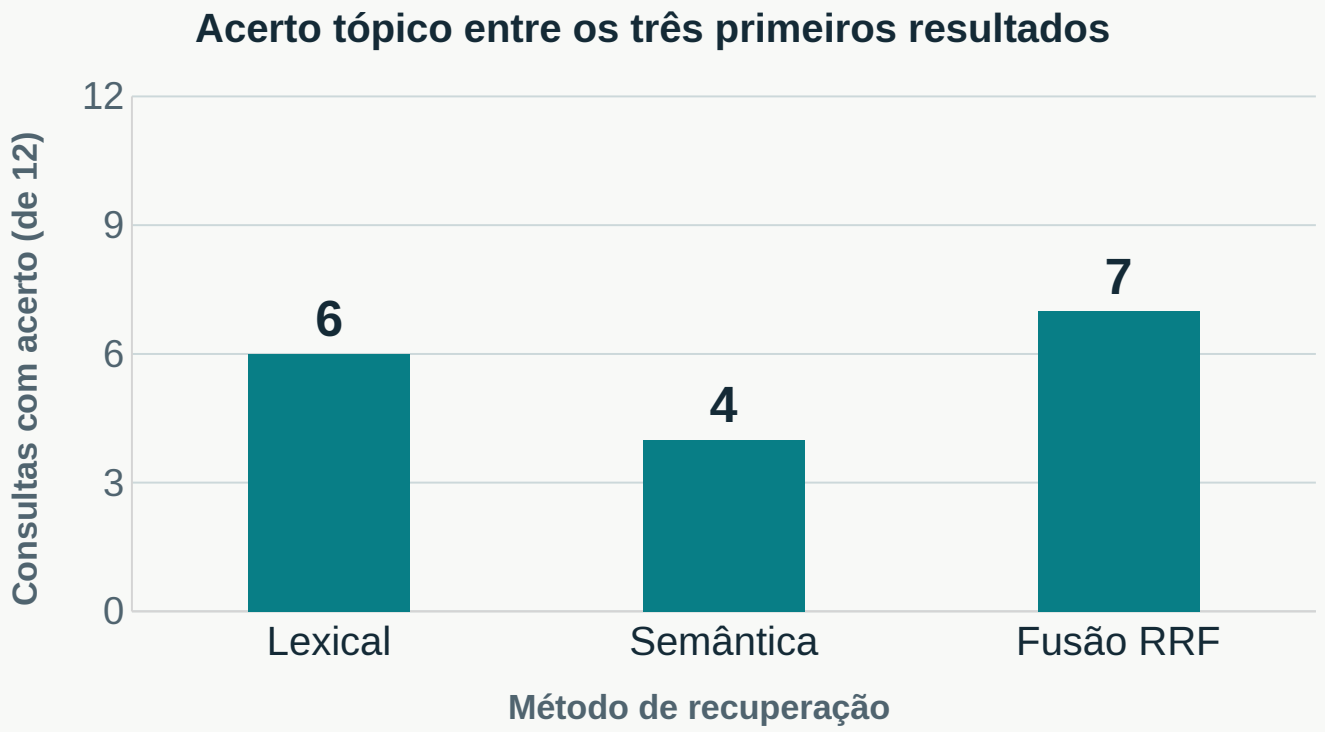
Continuidade do estudo

Problema a partir do assunto atual
Fontes e recomendações identificadas
Revisão de contrato explicitada

São resultados de engenharia, com qualidade pedagógica ainda em avaliação

Evidências locais e limites detalhados nas notas.

Recuperação: resultado exploratório



12 consultas em português

302 textos externos
Acerto por título no top-3

Fusão acertou um caso a mais
Embeddings do início do texto
Busca lexical segue como padrão

A amostra não sustenta superioridade geral da fusão

Referências R6, R8, R15. Fontes e evidências detalhadas nas notas.

Modelo local: cinco respostas problemáticas

Questão	Gabarito	Falha registrada
BFS	[0, 1, 1, 2]	Campo result ausente e distâncias incorretas
DFS	4 vértices	Resultado informado: 1
DP	5 sequências	JSON truncado ou inválido
Prefixos	5	Valor correto em outra chave e razão errada
Segment Tree	8	Resultado 5 e justificativa menciona 6

0/5 no campo e valor exigidos, com erros de formato e de raciocínio

Evidências locais e limites detalhados nas notas.

Falhas confirmadas e causas prováveis

Problema e evidência	Causa ou hipótese	Consequência e ação
Qwen 3B: timeout de 300,11 s	Custo local elevado é hipótese Não houve perfil causal completo	Medir RSS e latência Comparar modelo menor
SegTree fora das estatísticas	Currículo contém nove tópicos Contagem usa título exato	Prática pode sumir do resumo Unificar taxonomia
TLE externo: HTTP 403	Origem não verificada no relatório	Cobertura parcial Buscar acesso autorizado
Variação superficial de exercícios	Objetivo do contrato permanece fixo	Diversidade limitada Medir mudança estrutural

Os diagnósticos distinguem causa demonstrada e hipótese explicativa

Evidências locais e limites detalhados nas notas.

Contribuição e maturidade científica

Contribuição demonstrável

Integração de métodos existentes
Contratos com verificadores próprios
Proveniência e continuidade do estudo
Experimentos exploratórios auditáveis

Questões ainda abertas

Ganho de aprendizagem
Correção geral do feedback
Novidade estrutural dos problemas
Superioridade entre modelos e métodos

O protótipo sustenta uma base experimental, sem reivindicar novo algoritmo de IA

Referências R1, R2, R3. Fontes e evidências detalhadas nas notas.

Quatro direções de pesquisa

Direção	Hipótese a testar	Evidência necessária
Competências e pré-requisitos	Recuperação estruturada melhora alinhamento	Recall anotado e cobertura de competências
Geração pedagógica	Objetivo explícito melhora adequação	Rubrica cega e teste de transferência
Verificação algorítmica	Mutantes aumentam detecção de falhas	FPR, FNR e taxa de mutantes eliminados
Diversidade estrutural	Alterar operações supera trocar narrativa	Deduplicação estrutural e avaliação especialista

Ontologia e grafo de competências são propostas futuras

Referências R1, R2, R9. Fontes e evidências detalhadas nas notas.

Próximo experimento controlado

Condição proposta	Contexto do gerador	Validação posterior
A	LLM sem recuperação	Auditoria externa comum
B	LLM com RAG semântico	Auditoria externa comum
C	Recuperação estruturada por competência	Auditoria externa comum
D	Recuperação estruturada por competência	Verificação automática + auditoria comum

Medir validade, alinhamento, diversidade, tempo e memória sob o mesmo protocolo

Referências R5, R6, R9. Fontes e evidências detalhadas nas notas.

Conclusões e prioridades

O que podemos defender

Juiz e integração funcionam nos testes
Fontes e resultados são rastreáveis
O protótipo expõe limites reais da IA

O que deve vir agora

Unificar competências e estatísticas
Criar benchmark independente
Comparar geração com validação
Avaliar aprendizagem com estudantes

A próxima contribuição deve demonstrar um efeito controlado e reproduzível

Referências R1, R2, R3. Fontes e evidências detalhadas nas notas.

Referências principais

Zhou et al. AutoCode. ICLR 2026. arXiv:2510.12803

Su, Nie e Meng. OI-Assistant. 2025. DOI:10.15388/ioi.2025.09

Ez-zaouia e Boumarafi. Codigen. 2025. DOI:10.1109/VL-HCC65237.2025.00038

Vaswani et al. Attention Is All You Need. 2017. arXiv:1706.03762

Lewis et al. Retrieval-Augmented Generation. 2020. arXiv:2005.11401

Reimers e Gurevych. Sentence-BERT. 2019. DOI:10.18653/v1/D19-1410

Robertson e Zaragoza. BM25 and Beyond. 2009. DOI:10.1561/1500000019

Cormack, Clarke e Büttcher. RRF. 2009. DOI:10.1145/1571941.1572114

Referências pedagógicas, fontes técnicas e evidências completas nas notas e documentos